

پروژه پایانی مبانی سیستم های هوشمند

تحلیل جامع و پیاده سازی خط لوله یادگیری ماشین روی دیتاست بیماری قلبی

امیرحسین رضائی ۴۰۰۵۷۲۳ - مهسان قلمی ۴۰۰۸۱۵۳

<https://github.com/MahsanGhalami/Fundamentals-of-Intelligent-Systems-4041>

هدف این پروژه طراحی، پیاده سازی و ارزیابی یک خط لوله ی کامل یادگیری ماشین برای پیش بینی برچسب بیماری قلبی است. مسئله به صورت یک طبقه بندی دودویی تعریف می شود که در آن متغیر هدف (target) نشان دهنده ی وجود یا عدم وجود بیماری است که ۱ = وجود بیماری و ۰ = عدم وجود بیماری. اهمیت این مسئله از آن جا ناشی می شود که در کاربردهای پزشکی، تصمیم گیری نهایی فقط به دقت کلی محدود نیست و معمولاً هزینه ی خطای منفی کاذب (FN) می تواند از خطای مثبت کاذب (FP) مهم تر باشد؛ بنابراین علاوه بر Accuracy، معیارهای حساس تر مانند Precision، Recall، F1-Score و نیز معیارهای آستانه ناوابسته مانند ROC-AUC و Average Precision (PR-AUC/AP) نیز باید گزارش شوند.


معرفی مجموعه داده ی انتخاب شده

برای این پروژه از دیتاست Heart Disease Dataset در Kaggle استفاده شده است ، با لینک زیر :

<https://www.kaggle.com/yasserh/heart-disease-dataset>

طبق توضیح رسمی صفحه ی دیتاست و همچنین منبع اصلی UCI ، پایگاه داده ی Heart Disease در اصل شامل ۷۶ ویژگی است، اما تقریباً همه ی آزمایش ها و پیاده سازی های استاندارد در ادبیات یادگیری ماشین از زیر مجموعه ی ۱۴ ویژگی استفاده می کنند و ستون هدف (target) به حضور بیماری قلبی اشاره دارد.

در نوت بوک finalproject ، پس از بارگذاری فایل heart.csv ، ابعاد داده به صورت (303, 14) Shape: گزارش شده است؛ یعنی دیتاست شامل ۳۰۳ نمونه و ۱۴ ستون است که یکی از ستون ها نقش متغیر هدف را دارد و ۱۳ ستون دیگر ویژگی های ورودی را تشکیل می دهند. بر اساس خروجی کد ، ستون هدف با نام target شناسایی شده و توزیع کلاس ها به صورت زیر است: تعداد نمونه های کلاس ۱ برابر ۱۶۵ و کلاس ۰ برابر ۱۳۸ (تقریباً ۵۴٫۴۶٪ در برابر ۴۵٫۵۴٪). این توزیع نشان می دهد مسئله کاملاً نا متوازن نیست، اما همچنان استفاده از معیارهایی مانند F1 و PR-AUC در کنار Accuracy برای ارزیابی واقع بینانه ضروری است ، چون Accuracy به تنهایی می تواند تصویر ناقصی از عملکرد در هر کلاس بدهد.



از نظر ماهیت متغیرها، در پیاده‌سازی ویژگی‌ها به دو دسته ی عددی و دسته ای تفکیک شده اند تا پیش پردازش مناسب هر نوع داده انجام شود. مطابق خروجی نوت بوک، ویژگی های عددی شامل age, trestbps, chol, thalach, oldpeak و ویژگی های گسسته شامل sex, cp, fbs, restecg, exang, slope, ca, thal در نظر گرفته شده‌اند. این تفکیک از منظر مهندسی ویژگی و طراحی (خط لوله) Pipeline اهمیت دارد، زیرا روش های استاندارد Sklearn مثل ColumnTransformer دقیقاً برای همین سناریو طراحی شده‌اند که روی ستون های مختلف، تبدیل های متفاوت اعمال شود و کل فرایند در قالب یک Pipeline تکرار پذیر و بدون نشت اطلاعات باقی بماند.

```
Numeric: ['age', 'trestbps', 'chol', 'thalach', 'oldpeak']
Categorical: ['sex', 'cp', 'fbs', 'restecg', 'exang', 'slope', 'ca', 'thal']
```

در نهایت، صورت مسئله ی پروژه با این دیتاست به شکل یک Binary Classification استاندارد فرمول بندی می‌شود. پیش‌بینی اینکه آیا بیمار از نظر داده های بالینی موجود در ویژگی ها، در کلاس بیماری قلبی قرار می‌گیرد یا خیر.

پیش‌پردازش داده‌ها (Data Preprocessing)

در این پروژه، پیش پردازش داده ها به صورت تابع محور و تکرار پذیر طراحی شده است؛ یعنی به جای اجرای جداگانه ی مراحل پاک سازی تبدیل روی کل داده، همه ی مراحل در قالب Pipeline و ColumnTransformer قرار گرفته اند. این انتخاب باعث می‌شود در زمان Cross-Validation و Hyperparameter Tuning هر تبدیل فقط روی داده ی آموزش همان fold فیت شود و از نشت اطلاعات (data leakage) جلوگیری گردد؛ Sklearn نیز صراحتاً استفاده از Pipeline را یکی از راه حل های استاندارد برای جلوگیری از leakage در پیش پردازش معرفی می‌کند.

در نوت‌بوک finalproject ابتدا وضعیت داده از نظر کامل بودن بررسی شده است. خروجی df.info() نشان می دهد دیتاست شامل ۳۰۳ نمونه و ۱۴ ستوناست و تمام ستون‌ها دارای ۳۰۳ مقدار non-null هستند؛ همچنین جمع مقادیر گم‌شده برای همه ی ستون‌ها صفر گزارش شده است. با وجود نبود داده ی گم‌شده در این نسخه از دیتاست، در خط‌لوله از SimpleImputer استفاده شده تا از نظر مهندسی نرم افزار و قابلیت تعمیم کد، فرآیند در برابر نسخه های دیگر داده (یا حالت هایی که در عمل داده ناقص

باشد) مقاوم باقی بماند. SimpleImputer یک روش تک متغیره برای جایگزینی مقادیر گمشده با آمارهای توصیفی مثل میانه (median) یا بیشترین فراوانی (most_frequent) است .

<class 'pandas.core.frame.DataFrame'>

RangeIndex: 303 entries, 0 to 302

Data columns (total 14 columns):

#	Column	Non-Null Count	Dtype
0	age	303 non-null	int64
1	sex	303 non-null	int64
2	cp	303 non-null	int64
3	trestbps	303 non-null	int64
4	chol	303 non-null	int64
5	fbs	303 non-null	int64
6	restecg	303 non-null	int64
7	thalach	303 non-null	int64
8	exang	303 non-null	int64
9	oldpeak	303 non-null	float64
10	slope	303 non-null	int64
11	ca	303 non-null	int64
12	thal	303 non-null	int64
13	target	303 non-null	int64

dtypes: float64(1), int64(13)


memory usage: 33.3 KB

Missing values per column:

age	0
sex	0
cp	0
trestbps	0
chol	0
fbs	0
restecg	0
thalach	0
exang	0
oldpeak	0
slope	0
ca	0
thal	0
target	0
dtype:	int64

	count	mean	std	min	25%	50%	75%	max
age	303.0	54.366337	9.082101	29.0	47.5	55.0	61.0	77.0
sex	303.0	0.683168	0.466011	0.0	0.0	1.0	1.0	1.0
cp	303.0	0.966997	1.032052	0.0	0.0	1.0	2.0	3.0
trestbps	303.0	131.623762	17.538143	94.0	120.0	130.0	140.0	200.0
chol	303.0	246.264026	51.830751	126.0	211.0	240.0	274.5	564.0
fbs	303.0	0.148515	0.356198	0.0	0.0	0.0	0.0	1.0
restecg	303.0	0.528053	0.525860	0.0	0.0	1.0	1.0	2.0
thalach	303.0	149.646865	22.905161	71.0	133.5	153.0	166.0	202.0
exang	303.0	0.326733	0.469794	0.0	0.0	0.0	1.0	1.0
oldpeak	303.0	1.039604	1.161075	0.0	0.0	0.8	1.6	6.2
slope	303.0	1.399340	0.616226	0.0	1.0	1.0	2.0	2.0
ca	303.0	0.729373	1.022606	0.0	0.0	0.0	1.0	4.0
thal	303.0	2.313531	0.612277	0.0	2.0	2.0	3.0	3.0
target	303.0	0.544554	0.498835	0.0	0.0	1.0	1.0	1.0

در ادامه همبستگی ویژگی‌های عددی تحلیل شد. در نقشه حرارتی حاشیه نویسی شده، چند الگوی معنی دار مشاهده گردید: رابطه ی منفی نسبتاً قابل توجه میان age و thalach (حدود -۰,۴۰) نشان می‌دهد با افزایش سن، بیشینه ضربان قلب کاهش می‌یابد؛ همچنین همبستگی منفی oldpeak با slope (حدود -۰,۵۸) مشاهده شد که می‌تواند به هم پوشانی اطلاعاتی میان این متغیر ها اشاره داشته باشد. با این حال، همبستگی‌های بسیار بالا (نزدیک ۱ یا -۱) مشاهده نشد؛ بنابراین خطر هم خطی شدید که می‌تواند تفسیر ضرایب مدل‌های خطی را دچار ناپایداری کند، محدود ارزیابی شد.



از نظر نوع داده، ویژگی‌ها در کد پروژه به دو گروه عددی و دسته‌ای تفکیک شده‌اند و برای هر گروه یک مسیر پیش پردازش اختصاصی تعریف شده است. این دقیقاً مطابق کاربرد ColumnTransformer است که برای داده‌های ناممکن طراحی شده تا بتوان روی ستون‌های عددی و دسته‌ای تبدیل‌های متفاوت اعمال کرد، برای مثال: استانداردسازی عددی‌ها و One-Hot برای دسته‌ای‌ها. در مسیر ستون‌های عددی، ابتدا Imputation با میانگین انجام می‌شود و سپس در سناریوی مدل‌های خطی استانداردسازی توسط StandardScaler اعمال می‌گردد. اهمیت استانداردسازی در اینجا به ماهیت مدل‌های خطی برمی‌گردد Logistic Regression معمولاً از استانداردسازی سود می‌برد، زیرا مقیاس ویژگی‌ها روی بهینگی و پایداری بهینه‌سازی و نیز اثرگذاری منظم‌سازی (regularization) اثر می‌گذارد؛ در مقابل، مدل‌های درختی معمولاً به اسکیل حساس نیستند.

برای ویژگی‌های دسته‌ای نیز یک مسیر مستقل تعریف شده است که شامل Imputation با بیشترین فراوانی و سپس OneHotEncoder است. این رمزگذاری باعث می‌شود مدل‌های خطی و بسیاری از مدل‌های مبتنی بر فاصله، بتوانند اثر هر دسته را به طور جداگانه یاد بگیرند و همچنین با `handle_unknown="ignore"` در زمان برخورد با سطوح جدید در داده‌ی ارزیابی دچار خطا نشوند. ایده‌ی کلی این طراحی در کد پروژه این است که پیش پردازش به صورت یک جزء رسمی از مدل تعریف شود تا در کل چرخه‌ی Train/Validation/Test و CV، دقیقاً یکسان و قابل تکرار باقی بماند.

نکته‌ی مهم تحلیل اثر پیش پردازش روی نتایج است. در کد این تحلیل با تعریف سناریوهای متفاوت پیش پردازش و مقایسه‌ی خروجی متریک‌ها انجام شده است. به طور مشخص، برای مدل Random Forest دو نسخه‌ی پیش پردازش بررسی شده است: مسیر درختی بدون scaler و مسیر درختی اسکیل شده. خروجی جدول مقایسه‌ی Train/Val/Test نشان می‌دهد که RF (scaled preprocess) دقیقاً عملکرد یکسانی دارند برای نمونه `val_f1=0.823529` و `test_f1=0.79245` در هر دو حالت، که این مشاهده با انتظار نظری نیز هم خوان است: چون Random Forest بر مبنای مقایسه‌ی های آستانه‌ای و تقسیم‌بندی درختی عمل می‌کند، تغییر مقیاس ویژگی‌ها معمولاً ساختار تصمیم‌گیری آن را تغییر معناداری نمی‌دهد.

کاهش ابعاد (Dimensionality Reduction)

در این پروژه، کاهش بعد با دو هدف مجزا دنبال شده است: کاهش بعد برای مدل‌سازی به منظور کنترل پیچیدگی نمایش ویژگی‌ها و بررسی اثر آن بر عملکرد، و نمایش دو بعدی داده برای تحلیل کیفی ساختار کلاس‌ها. این تفکیک اهمیت دارد زیرا همه‌ی روش‌های کاهش بعد الزاماً برای بهبود دقت طبقه‌بندی طراحی نشده‌اند، برخی مثل t-SNE عمدتاً ابزار مصورسازی‌اند و برای آموزش مستقیم مدل توصیه نمی‌شوند.

در بخش کاهش بعد برای مدل‌سازی، در نوت بوک کد از PCA به عنوان روش خطی کاهش بعد استفاده شده است. از دیدگاه نظری، PCA داده را روی زیر فضایی پروجکت می‌کند که در آن، مؤلفه‌ها جهت‌های بیشینه‌سازی واریانس هستند بنابراین PCA با حفظ


بیشترین واریانس ممکن در تعداد مؤلفه های کمتر، ابعاد را کاهش می دهد و می تواند هم به کاهش نویز و کمک کند. در پیاده سازی Sklearn، امکان تعیین n_components به صورت نسبت واریانس حفظ شده وجود دارد و در کد پروژه مقدار n_components=0.95 و در GridSearch برای LogReg+PCA مقادیر ۰.۹۰-۰.۹۵-۰.۹۹ برای حفظ بخش عمده ای از واریانس انتخاب شده است.

با این حال، نتایج نشان می دهد اثر PCA به مدل وابسته است و در این دیتاست تضمین بهبود ایجاد نکرده است. در ارزیابی پایدار (Repeated Stratified CV)، Logistic Regression بدون PCA بهترین یا نزدیک به بهترین نتیجه را ثبت کرده (cv_f1_mean≈0.8692) و نسخه ی LogReg+PCA بسیار نزدیک بوده (۰.۸۶۸۶)؛ به بیان دیگر، PCA برای مدل خطی در این مسئله بهبود محسوسی ایجاد نکرده اما عملکرد را نیز تخریب نکرده است. در مقابل، برای Random Forest کاهش بعد خطی اثر منفی پررنگ داشته است RF+PCA: در CV افت شدید نشان داده (cv_f1_mean≈0.6889) و در Test نیز F1 به طور محسوسی پایین تر آمده (test_f1≈0.6923) این مشاهده با تحلیل نظری سازگار است، درخت ها و جنگل های تصادفی بر تقسیم بندی آستانه ای روی ویژگی ها تکیه دارند و تبدیل خطی PCA می تواند ساختار محلی و قابلیت تفکیک پذیری مبتنی بر ویژگی های خام را تضعیف کند. در نتیجه، در این پروژه PCA بیشتر برای مدل های خطی بی ضرر و برای مدل های درختی نامناسب ارزیابی شده است.


group	model	train_f1	val_f1	test_f1	train_acc	val_acc	test_acc	train_auc	val_auc	test_auc	train_pr_auc	val_pr_auc	test_pr_auc	overfit_gap_f1 (train-val)
untuned	LogReg+PCA	0.901288	0.833333	0.800000	0.891509	0.822222	0.782609	0.945675	0.894	0.864762	0.952522	0.917308	0.889591	0.067954
untuned	RF	0.904348	0.823529	0.792453	0.896226	0.800000	0.760870	0.962438	0.894	0.866667	0.966667	0.919669	0.895261	0.080818
untuned	RF (scaled preprocess)	0.904348	0.823529	0.792453	0.896226	0.800000	0.760870	0.962438	0.894	0.866667	0.966591	0.919669	0.895261	0.080818
untuned	LogReg	0.897436	0.816327	0.807692	0.886792	0.800000	0.782609	0.948723	0.894	0.872381	0.952956	0.915503	0.899852	0.081109
untuned	AdaBoost	0.927039	0.816327	0.784314	0.919811	0.800000	0.760870	0.980816	0.898	0.836190	0.984695	0.922635	0.868644	0.110712
untuned	RF+PCA	0.766520	0.807692	0.692308	0.750000	0.777778	0.652174	0.869924	0.732	0.744762	0.893531	0.722828	0.800356	-0.041172
untuned	AdaBoost+PCA	0.767241	0.800000	0.627451	0.745283	0.755556	0.586957	0.819677	0.791	0.688571	0.836640	0.804562	0.765156	-0.032759

از منظر معیار دیگر یعنی هزینه ی محاسباتی و سرعت آموزش استنتاج، PCA در این پروژه نقش دوگانه داشته است. از یک سو، چون پیش پردازش شامل One-Hot است، فضای ویژگی پس از تبدیل می تواند نسبت به حالت خام بزرگ تر شود، در چنین وضعی PCA می تواند تعداد مؤلفه ها را کاهش دهد و به خصوص برای مدل های خطی که هزینه ی آموزش آن ها به تعداد ویژگی ها وابسته است احتمالاً زمان آموزش و حساسیت به نویز را کاهش دهد. از سوی دیگر، خود PCA یک مرحله ی اضافی محاسباتی به پایپ لاین اضافه می کند و اگر کاهش بعد به اندازه کافی رخ ندهد یا مدل به ویژگی های خام وابسته باشد مانند RF، نه تنها سودی ندارد بلکه می تواند دقت را هم کم کند. بنابراین نتیجه ی عملی در کد پروژه این است که کاهش بعد با PCA باید مدل محور تصمیم گیری شود و صرفاً به عنوان یک گام پیش فرض در همه مدل ها قرار نگیرد.

برای توجیه کمی کاهش ابعاد، نسبت واریانس توضیح داده شده توسط مؤلفه های اصلی استخراج و نمودار Scree ترسیم شد. نشان داده شد که چند مؤلفه ابتدایی سهم بزرگی از واریانس را توضیح می دهند (به طور ویژه مؤلفه اول با سهمی حدود ۰/۲۵) و سپس سهم مؤلفه ها به صورت تدریجی کاهش می یابد. بنابراین تمرکز اطلاعات داده در تعداد محدودی از جهت های اصلی تأیید شد. این تحلیل مطابق با تعریف `explained_variance_ratio_` در پیاده سازی PCA در `scikit-learn` انجام شده است.




در گام بعد، واریانس تجمعی بررسی شد. مشاهده شد که با افزایش تعداد مؤلفه ها، واریانس تجمعی به سرعت رشد می کند و طبق خروجی چاپ شده، برای رسیدن به پوشش حداقل ۹۵٪ واریانس، به ۱۴ مؤلفه نیاز بوده است. لذا نشان داده شد که امکان کاهش ابعاد (بدون افت شدید اطلاعات) وجود دارد و انتخاب تعداد مؤلفه ها به جای تصمیم سلیقه ای، بر اساس معیار کمی پوشش واریانس انجام پذیر بوده است. استفاده از `explained_variance_ratio_` و جمع تجمعی آن، روش استاندارد برای تصمیم گیری در این مرحله تلقی می شود.



Components needed for >=95% variance (within `pca_vis`): 14

در بخش تصویری سازی، از t-SNE برای نمایش داده در فضای دو بعدی استفاده شده است. طبق مستندات Sklearn، t-SNE ابزاری برای visualize high-dimensional data است و پارامترهایی مانند perplexity و learning_rate کیفیت و پایداری نمایش را تحت تأثیر قرار می دهند. برای کاهش هزینه محاسباتی و پایداری، ابتدا یک PCA کم بعد (مثلاً تا ۲۰ مؤلفه) اجرا و سپس t-SNE روی خروجی PCA اعمال شده است. این کار از نظر عملی رایج است زیرا t-SNE روی داده ی بسیار پر بعد می تواند کند و حساس باشد و کاهش بعد اولیه می تواند بار محاسباتی را کم کند. از نظر تحلیلی، پراکندگی دو بعدی t-SNE در خروجی های شما جدا سازی نسبی کلاس ها را نشان می دهد اما هم پوشانی هم وجود دارد. این با نتایج متریک ها سازگار است داده سیگنال کافی برای رسیدن به F1 و AUC مناسب دارد، اما جداسازی کامل نیست و بنابراین اختلاف های کوچک بین مدل ها طبیعی است.



انتخاب و آموزش مدل ها

در این بخش، انتخاب مدل ها به گونه ای انجام شده که هم شرط رعایت شود و هم یک روش پیشرفته تر از مباحث درس در سطح Ensemble/Boosting به پروژه اضافه گردد. در نوت بوک finalproject سه خانواده مدل پیاده سازی شده اند.

LogisticRegression به عنوان مدل خطی کلاسیک و تفسیرپذیر، Random Forest به عنوان روش ensemble مبتنی بر bagging و درخت تصمیم، و AdaBoost به عنوان روش boosting که به شکل ترتیبی یاد گیرنده های ضعیف را به یک مدل قوی تبدیل می کند. این ترکیب امکان مقایسه ی یک مدل با ظرفیت پایین و بایاس بیشتر در برابر مدل های با ظرفیت بالاتر و ریسک واریانس overfitting را فراهم می کند و در نهایت انتخاب مدل نهایی می تواند بر اساس شواهد تجربی به ویژه crossfold validation توجیه شود.

از منظر نظری، Logistic Regression یک مدل خطی برای طبقه بندی دودویی است که با استفاده از تابع لجستیک احتمال کلاس مثبت را برآورد می کند و در sklearn به صورت پیش فرض همراه با regularization ارائه می شود. پارامتر کلیدی آن C

است که طبق مستندات رسمی sklearn معکوس شدت منظم سازی است، یعنی هر چه C کوچک تر باشد regularization قوی تر است و مدل تمایل دارد ضرایب کوچک تر و مرز تصمیم ساده تری تولید کند. در مسئله ی حاضر که تعداد نمونه ها محدود است (۳۰۳ نمونه) و داده ها ترکیبی از ویژگی های عددی و دسته ای اند، این ویژگی Logistic Regression مزیت مهمی محسوب می شود، مدل می تواند با کنترل شدت regularization از overfitting جلوگیری کند، به خصوص وقتی پس از One-Hot تعداد ویژگی های مؤثر افزایش می یابد. به همین دلیل در مسیر پیش پردازش خطی شامل استانداردسازی نیز هست، چون در مدل های regularized خطی، مقیاس ویژگی ها روی رفتار penalty و پایداری بهینه سازی اثرگذار است.

در کنار آن، Random Forest به عنوان یک روش ensemble کلاسیک انتخاب شده است که با ساخت چندین درخت تصمیم روی نمونه های bootstrap و سپس تجمیع رای ها، معمولا واریانس یک درخت منفرد را کاهش می دهد. Sklearn برای RandomForestClassifier پارامترهایی مانند n_estimators, max_depth, max_features, bootstrap, max_samples, ccp_alpha معرفی می کند که ابزار کنترل ظرفیت و رفتار تعمیم مدل هستند. در نوت بوک کد علاوه بر نسخه ی پایه RF، سناریوی مقایسه ی پیش پردازش نیز اضافه شده است RF با و بدون StandardScaler که نتایج نشان داده اند که اسکیل کردن روی RF اثری معنادار ندارد، عملکرد RF و RF-scaled عملا یکسان گزارش شده. که با انتظار نظری نیز سازگار است؛ زیرا تصمیم گیری درخت ها بر مبنای آستانه گذاری روی مقدار ویژگی هاست و تغییر مقیاس یکنواخت معمولا ترتیب داده ها را تغییر نمی دهد. همچنین در نسخه ی اصلاح شده ی RF که پس از اور فیت شدن جنگل تصادفی اول تغییراتی از جمله اضافه کردن پارامترهای کنترل overfitting مانند max_samples و ccp_alpha انجام شد که هر دو در مستندات رسمی Sklearn به عنوان ابزارهای کنترل ساختار درخت نمونه برداری قابل استفاده اند.

مدل سوم، AdaBoost به عنوان یک روش پیشرفته تر در حد مباحث Ensemble/Boosting انتخاب شده است. مطابق تعریف Sklearn. AdaBoost یک meta-estimator است که ابتدا یک یادگیرنده پایه که در این پروژه DecisionTree با عمق کم است را روی داده آموزش می دهد و سپس در تکرار های بعدی با افزایش وزن نمونه های بد طبقه بندی شده، یادگیرنده های جدید را طوری می سازد که روی موارد دشوار تمرکز کنند. دو پارامتر کلیدی در AdaBoost یعنی n_estimators و learning_rate در عمل یک trade-off ایجاد می کنند، افزایش تعداد تخمین زن ها ظرفیت مدل را بالا می برد و learning_rate سهم هر مرحله boosting را تنظیم می کند. در این پروژه این پارامتر ها در بخش تیونینگ بررسی شده اند تا هم تعمیم بهتر شود و هم از overfitting جلوگیری گردد.

توجیه انتخاب مدل ها با توجه به نوع داده و مسئله

با توجه به ماهیت داده که حجم نمونه نسبتا محدود دارد، ترکیب ویژگی های عددی و دسته ای، و هدف دودویی، این سه مدل از نظر علمی مکمل یکدیگرند. Logistic Regression یک baseline قوی و تفسیرپذیر ارائه می دهد و به کمک regularization

می‌تواند در داده‌های کوچک پایدار باشد. Random Forest ظرفیت بالاتری دارد و می‌تواند روابط غیر خطی و تعامل بین ویژگی‌ها را مدل کند، اما در داده‌های کوچک مستعد overfitting است و بنابراین باید با کنترل ظرفیت مثلاً محدودیت عمق، برگ‌ها، و pruning قضاوت شود. AdaBoost نیز به عنوان یک روش boosting می‌تواند خطاهای سیستماتیک را کاهش دهد و در برخی مسائل با ساختار قابل یادگیری، نسبت به bagging مزیت نشان دهد، اما آن هم ممکن است در صورت تنظیم نامناسب overfit کند. بنابراین انتخاب این سه خانواده مدل امکان ارائه‌ی تحلیل Bias-Variance و دفاع علمی از مدل نهایی را فراهم می‌کند.

تحلیل عملکرد و انتخاب مدل با ارجاع به خروجی

در خروجی‌های نوت‌بوک، مقایسه‌ی مدل‌ها هم در سطح Train/Validation/Test و هم در سطح Repeated Stratified CV انجام شده است. وقتی حجم داده محدود است، نتیجه‌گیری اصلی باید بر اساس CV پایدار باشد، نه صرفاً یک split ثابت زیرا یک split خاص ممکن است خوش‌شانسی یا بد‌شانسی داشته باشد.

در نتایج CV تکرار شونده Logistic Regression بدون PCA بهترین یا نزدیک به بهترین cv_f1_mean را نشان داده و LogReg+PCA بسیار نزدیک به آن قرار گرفته است این یعنی مدل خطی از نظر تعمیم میانگین پایدارتر است. در مقابل، نسخه‌های درختی و boosting اگرچه در برخی سناریوهای Test/Validation می‌توانند F1 بالاتری تولید کنند، اما اختلاف-train val و آنچه در Learning Curve دیده می‌شود می‌تواند نشانه‌ای از ظرفیت بالاتر و ریسک overfitting باشد.

تنظیم ابرپارامترها (Hyperparameter Tuning)

در نوت بوک پروژه، تنظیم ابر پارامترها به صورت نظام مند و قابل گزارش انجام شده است به این معنا که به جای تغییر دستی چند مقدار محدود، از دو راهکار استاندارد Sklearn یعنی GridSearchCV و RandomizedSearchCV استفاده شده است. از منظر تئوری، Grid Search همه‌ی ترکیب‌های یک شبکه‌ی از پیش تعریف شده از پارامترها را به صورت exhaustive ارزیابی می‌کند و در پایان بهترین ترکیب را بر اساس امتیاز میانگین Cross-Validation انتخاب می‌کند. در مقابل، Randomized Search به جای پیمایش کامل شبکه، از فضای پارامترها نمونه برداری تصادفی انجام می‌دهد که با کنترل تعداد نمونه‌ها توسط n_iter انجام میشود و در فضاهای بزرگ تر معمولاً با هزینه‌ی محاسباتی کمتر به نتیجه می‌رسد. Sklearn برای هر دو روش، علاوه بر بهترین مدل (best_estimator_)، گزارش بهترین امتیاز میانگین (best_score_) CV و بهترین پارامترها (best_params_) را فراهم می‌کند و همچنین تمام نتایج آزمون‌شده را در cv_results ذخیره می‌نماید که برای گزارش دقیق همه‌ی ترکیب‌ها مناسب است.

از نظر طراحی آزمایش، در هر سه تیونینگ موجود در این پروژه، معیار امتیاز دهی اصلی F1-score انتخاب شده است، این انتخاب با ماهیت مسئله ی پزشکی سازگار است، زیرا F1 بین precision و recall توازن برقرار می کند و وقتی هزینه ی خطا ها یکسان فرض نشود یا کلاس ها کاملاً متوازن نباشند، نسبت به Accuracy تصویر دقیق تری از کیفیت تصمیم دودویی ارائه می دهد. در این پروژه، فرآیند Search روی داده ی آموزش (Train) انجام شده و ارزیابی درون جستجو با یک Cross-Validation طبقه بندی شده (Stratified) صورت گرفته است تا نسبت کلاس ها در fold ها حفظ شود. سپس مدل بهینه شده روی Validation/Test نیز جداگانه ارزیابی شده تا ریسک خوش بینی ناشی از انتخاب پارامتر روی همان داده کنترل گردد. همچنین در Search ها گزینه ی return_train_score=True فعال بوده و این امکان را ایجاد کرده که شکاف عملکرد train/test fold نشانه ی overfitting است به صورت کمی بررسی شود. این دقیقاً با هدف درس مبنی بر تحلیل overfitting/underfitting هم راستاست.

[20]:

	group	model	train_f1	val_f1	test_f1	train_acc	val_acc	test_acc	train_auc	val_auc	test_auc	train_pr_auc	val_pr_auc	test_pr_auc	overfit_gap_f1 (train-val)
0	tuned	LogReg+PCA (Tuned)	0.898305	0.823529	0.807692	0.886792	0.800000	0.782609	0.942537	0.900	0.876190	0.948461	0.924278	0.902491	0.07477
1	tuned	AdaBoost (Tuned)	0.885106	0.814815	0.836364	0.872642	0.777778	0.804348	0.941013	0.872	0.825714	0.940485	0.896519	0.855188	0.07029
2	tuned	RF (Tuned)	0.905172	0.807692	0.807692	0.896226	0.777778	0.782609	0.964231	0.894	0.855238	0.968895	0.919669	0.881488	0.09748
3	untuned	LogReg+PCA	0.901288	0.833333	0.800000	0.891509	0.822222	0.782609	0.945675	0.894	0.864762	0.952522	0.917308	0.889591	0.06795
4	untuned	RF	0.904348	0.823529	0.792453	0.896226	0.800000	0.760870	0.962438	0.894	0.866667	0.966667	0.919669	0.895261	0.08081
5	untuned	RF (scaled preprocess)	0.904348	0.823529	0.792453	0.896226	0.800000	0.760870	0.962438	0.894	0.866667	0.966591	0.919669	0.895261	0.08081
6	untuned	LogReg	0.897436	0.816327	0.807692	0.886792	0.800000	0.782609	0.948723	0.894	0.872381	0.952956	0.915503	0.899852	0.08110
7	untuned	AdaBoost	0.927039	0.816327	0.784314	0.919811	0.800000	0.760870	0.980816	0.898	0.836190	0.984695	0.922635	0.868644	0.11071
8	untuned	RF+PCA	0.766520	0.807692	0.692308	0.750000	0.777778	0.652174	0.869924	0.732	0.744762	0.893531	0.722828	0.800356	-0.04117
9	untuned	AdaBoost+PCA	0.767241	0.800000	0.627451	0.745283	0.755556	0.586957	0.819677	0.791	0.688571	0.836640	0.804562	0.765156	-0.03275

Logistic Regression + PCA برای GridSearchCV

در کد پروژه برای Logistic Regression نسخه ی PCA دار تیون شده است، زیرا این مدل هم به regularization و هم به انتخاب تعداد مؤلفه ها حساس است. از نظر تئوری، در Logistic Regression پارامتر کلیدی C معکوس شدت regularization است؛ کاهش C منجر به منظم سازی قوی تر و مدل ساده تر می شود و افزایش C آزادی مدل را افزایش می دهد. در این نوت بوک، شبکه ی جستجو شامل مقادیر چند گانه برای C و چند مقدار برای pca__n_components (نسبت واریانس حفظ شده) بوده است. خروجی Search در نوت بوک نشان می دهد بهترین ترکیب برای LogReg+PCA برابر با C=0.1 و pca__n_components=0.99 بوده و مقدار بهترین امتیاز CV-F1 نیز حدود ۰.۸۷۸۶ گزارش شده است. این نتیجه از نظر تحلیلی قابل تفسیر است، انتخاب C=0.1 نشان می دهد مقدار نسبتاً قوی تری از regularization به تعمیم کمک کرده و افزایش

واریانس حفظ شده به ۰,۹۹ احتمالاً از حذف بیش از حد اطلاعات در PCA جلوگیری کرده است. در کد پروژه علاوه بر `best_params`، جدول `cv_results_` برای نشان دادن رتبه بندی ترکیب ها و پراکندگی امتیازها کاملاً ارائه شده است.

Random Forest برای RandomizedSearchCV

برای Random Forest فضای پارامترها بزرگ تر و پیوسته تر است به ویژه وقتی `n_estimators`، `max_depth`، `min_samples_` و پارامترهای نمونه برداری هم زمان تغییر کنند، بنابراین استفاده از `RandomizedSearchCV` از نظر هزینه-فایده منطقی تر است. `RandomizedSearchCV` به صورت رسمی با پارامترهای `param_distributions` (که می تواند شامل توزیع های `scipy.stats` یا لیست مقدارها باشد) و `n_iter` (تعداد نمونه گیری) تعریف می شود.

در نوت بوک پروژه توزیع جستجو شامل پارامترهای ظرفیت و کنترل `overfitting` بوده است، تعداد درختها (`n_estimators`)، عمق (`max_depth`)، حداقل نمونه برای `split` و (`min_samples_split`، `min_samples_leaf`)، تعداد ویژگی های بررسی شده در هر (`max_features`) `split`، نسبت نمونه برداری در `bootstrap` با `max_samples`، و `pruning` با `ccp_alpha`. از نظر تئوری، این پارامترها مستقیماً پیچیدگی درخت ها و واریانس مدل را کنترل می کنند، محدود کردن عمق و افزایش حداقل نمونه ی برگ معمولاً `overfitting` را کاهش می دهد، `max_samples` اندازه ی مؤثر داده برای هر درخت را تنظیم می کند، و `ccp_alpha` ابزار `pruning` مبتنی بر `cost-complexity` است که Sklearn آن را به عنوان پارامتر رسمی در `RandomForestClassifier` ارائه می دهد.

بر اساس خروجی کد بهترین ترکیب RF شامل `n_estimators=963`، `max_depth=12`، `max_features=log2`، `min_samples_split=12`، `min_samples_leaf=4`، `max_samples≈0.664` و `ccp_alpha≈0.000404` بوده و بهترین امتیاز CV-F1 حدود ۰,۸۸۰۹ گزارش شده است. از منظر تحلیل، این نتیجه نشان می دهد مدل بهینه شده ظرفیت نسبتاً بالایی (عمق ۱۲) دارد اما هم زمان با `constraints` روی `leaf/split` و `pruning` و نمونه برداری کنترل شده تا تعمیم بهتر شود.

AdaBoost برای GridSearchCV

`AdaBoost` به عنوان روش `boosting`، به شدت به سه عامل نوع و ظرفیت یادگیرنده پایه (درخت کم عمق)، تعداد مراحل `boosting` (`n_estimators`) و نرخ یادگیری (`learning_rate`) حساس است. طبق تعریف رسمی Sklearn، `AdaBoost` یک `meta-estimator` است که با تنظیم وزن نمونه های بد طبقه بندی شده در تکرارهای بعدی، یادگیرنده های بعدی را روی نمونه های دشوارتر متمرکز می کند.

در کد پروژه GridSearch برای AdaBoost بر روی `clf__estimator_max_depth` ، `clf__n_estimators` و `clf__learning_rate` انجام شده است. خروجی نشان می‌دهد بهترین پارامترها `max_depth=1` , `learning_rate=0.05` , `n_estimators=100` بوده و بهترین CV-F1 حدود ۰,۸۷۴۴ گزارش شده است. stump (عمق ۱) به عنوان weak learner استاندارد AdaBoost شناخته می‌شود و نرخ یادگیری کوچک‌تر (۰,۰۵) همراه با تعداد estimator متوسط (۱۰۰) معمولاً یک تعادل مناسب میان bias/variance ایجاد می‌کند و از جهش‌های شدید در وزن دهی جلوگیری می‌کند.

ارزیابی و تکرارپذیری (Evaluation & Reproducibility)

در نوت‌بوک پروژه ارزیابی مدل‌ها به گونه‌ای طراحی شده که هم قابل تکرار باشد و هم برآورد عملکرد صرفاً به یک تقسیم تصادفی وابسته نماند. برای تضمین تکرارپذیری، یک مقدار ثابت برای `RANDOM_STATE` در کل پروژه تعریف و در نقاط کلیدی مثل تقسیم داده و مدل‌هایی که تصادفی بودن ذاتی دارند استفاده شده است. ثابت بودن `seed` باعث می‌شود اگر پروژه دوباره اجرا شود، همان تقسیم‌بندی‌ها و همان روند نمونه‌برداری‌های تصادفی تکرار گردد و نتایج باز تولید پذیر شوند.

در بخش تقسیم داده‌ها (Train/Validation/Test Split) ، کد از `train_test_split` در دو مرحله استفاده می‌کند، ابتدا جداسازی `Train` از یک مجموعه‌ی موقت، و سپس شکستن مجموعه‌ی موقت به `Validation` و `Test` نکته‌ی کلیدی این تقسیم‌بندی، استفاده از گزینه‌ی `stratify` است که طبق مستندات رسمی `Sklearn` باعث می‌شود تقسیم داده به صورت طبقه‌بندی شده انجام شود؛ یعنی نسبت کلاس‌ها در هر بخش حفظ گردد. این موضوع برای دیتاست‌های پزشکی حتی با عدم توازن خفیف نیز اهمیت دارد، زیرا بدون `stratify` ممکن است یک بخش مثل `Test` به طور تصادفی نمونه‌های یک کلاس را کمتر داشته باشد و ارزیابی را منحرف کند. بنابراین در این پروژه منطق تقسیم به صورت تقسیم سه‌گانه و حفظ توزیع کلاس‌ها است .

با این حال، اتکا به یک تقسیم ثابت اگر `stratified` باشد برای نتیجه‌گیری کافی نیست، زیرا عملکرد مدل می‌تواند به صورت معنادار به شانس همان `split` وابسته باشد. به همین دلیل در این پروژه علاوه بر جدول‌های `Train/Val/Test` ، برای یک ارزیابی پایدارتر نیز از `RepeatedStratifiedKFold` در کنار `cross_validate` استفاده شده است. در حالی که `RepeatedStratifiedKFold` روش `Stratified K-Fold` را چند بار با تصادفی‌سازی‌های متفاوت تکرار می‌کند و در هر بار، سهم کلاس‌ها را در `fold` ها حفظ می‌کند؛ بنابراین میانگین و انحراف معیار متریک‌ها روی مجموعه‌ای بزرگ از تقسیم‌ها محاسبه می‌شود و تخمین بهتری ارائه می‌دهد. این انتخاب به جای گزارش یک عدد منفرد، با گزارش میانگین و انحراف معیار می‌توان نشان دهد عملکرد مدل چقدر پایدار است .


در پیاده‌سازی کد، `cross_validate` به صورت چند متریکی طراحی شده است تا هم زمان معیار های مختلف مانند `Accuracy`، `F1`، `ROC-AUC` و `PR-AUC` محاسبه شود. کتابخانه `Sklearn` تاکید می‌کند که `cross_validate` می‌تواند چند معیار را از طریق `scoring` برگرداند و خروجی آن شامل آرایه‌ی امتیاز ها برای هر `fold` است. همچنین در صورت فعال بودن `return_train_score` می‌توان امتیازهای `train` را نیز دریافت کرد و از روی شکاف `train/test-fold` به وجود `overfitting` پی برد.

نکته‌ی تکمیلی مهم در تکرارپذیری این است که در این پروژه همه‌ی مراحل پیش پردازش داخل `Pipeline` قرار گرفته اند، این کار علاوه بر اینکه جلوی `data leakage` را می‌گیرد، تضمین می‌کند که در هر `fold` از `Cross-Validation`، تبدیل ها فقط روی داده‌ی آموزش همان `fold` فیت شوند و سپس روی داده‌ی `validation/test` همان `fold` اعمال گردند.

تحلیل نتایج و مصورسازی (Visualization & Analysis)


در این بخش، ارزیابی عملکرد مدل ها صرفا به گزارش چند معیار عددی محدود نشده و تحلیل بر مبنای نمودارهای تشخیصی انجام شده است؛ به گونه‌ای که هم توان تفکیک کلاس ها در دامنه‌ی ای از آستانه ها سنجیده شود و هم ماهیت خطاها به‌ویژه `FN` و `FP` و پایداری تعمیم پذیری مدل ها بررسی گردد. ارزیابی طبقه‌بندی، `ROC-AUC` به عنوان سنجه‌ی ای مبتنی بر نمره پیش‌بینی برای محاسبه مساحت زیر منحنی `ROC` به کار گرفته شده است، و منحنی `Precision-Recall` و `Average Precision` نیز برای تحلیل رفتار مدل در کلاس مثبت استفاده شده اند. همچنین از `Learning Curve` برای تفسیر الگوی بایاس-واریانس و اثر افزایش داده آموزشی بر شکاف تعمیم استفاده شده و `Calibration Curve (Reliability Diagram)` جهت سنجش میزان کالیبره بودن احتمال های پیش بینی شده ترسیم شده است.

برای ارزیابی کیفی ساختار داده و میزان جدا سازی پذیری دو کلاس، نمایش دو بعدی مبتنی بر `t-SNE` روی داده های `Train` پس از اعمال پیش پردازش و یک کاهش بعد اولیه جهت کنترل هزینه محاسباتی انجام شده است. در این نمایش، هم پوشانی قابل توجهی میان خوشه های دو کلاس مشاهده می‌شود؛ بنابراین انتظار مرز تصمیم کاملا خطی منطقی تلقی نمی شود و وجود بخشی از خطاها پیامد طبیعی هم پوشانی توزیع ها تفسیر می‌گردد.




۷-۱) تحلیل مدل پایه (LogReg Untuned) روی TEST


در ماتریس اغتشاش مدل پایه، مقادیر $TN=15$ ، $FP=6$ ، $FN=4$ ، $TP=21$ حاصل شده است؛ بدین معنا که در آستانه پیش فرض، بخش عمده ای از نمونه های مثبت شناسایی شده اند، هرچند هم خطای نوع اول (FP) و هم خطای نوع دوم (FN) همچنان حضور دارند. با توجه به ماهیت مسئله پزشکی، خطای FN معمولا به عنوان خطای پر هزینه تر تلقی می گردد؛ از این رو، کاهش FN به عنوان یکی از اهداف کاربردی محتمل در مراحل بعدی از طریق تغییر آستانه قابل طرح است. این تفسیر بر مبنای مشاهده مستقیم الگوی خطاها در Confusion Matrix ارائه شده و نه صرفا بر اساس یک معیار تجمیعی.



در منحنی ROC مدل پایه، $AUC \approx 0.872$ گزارش شده است که دلالت بر توان تفکیک کلی مناسب مدل در طیف آستانه ها دارد؛ زیرا محاسبه AUC از امتیاز های پیش بینی شده انجام می شود و مستقل از انتخاب یک آستانه منفرد تفسیر می گردد. به صورت مفهومی، ROC نشان می دهد که با جا به جایی آستانه تصمیم، نرخ درست مثبت (TPR) چگونه در ازای افزایش نرخ مثبت کاذب (FPR) تغییر می کند؛ از این رو، امکان تحلیل trade-off و انتخاب آستانه مناسب فراهم می گردد.




در منحنی Precision-Recall مدل پایه ، مقدار $AP \approx 0.900$ به دست آمده است که نشان می دهد مدل در رتبه بندی نمونه های مثبت و حفظ تعادل میان Precision و Recall در آستانه های مختلف عملکرد مطلوبی داشته است. از منظر تحلیلی، PR-Curve به طور خاص برای مطالعه خروجی یک طبقه بند دودویی و رفتار آن در کلاس مثبت به کار گرفته می شود و با تغییر آستانه، Precision در قبال افزایش Recall قابل مشاهده خواهد بود؛ بنابراین، مشاهده افت تدریجی Precision در سطوح بالاتر Recall به عنوان یک trade-off طبیعی تفسیر می شود




۷-۲) تحلیل مدل های Tuned روی TEST و مقایسه رفتاری


برای LogReg+PCA (Tuned) ، ماتریس اغتشاش روی TEST بدون تغییر و برابر با $TN=15$ ، $FP=6$ ، $FN=4$ ، $TP=21$ مشاهده شده است. از این مشاهده استنباط می شود که در آستانه پیش فرض، تصمیم دودویی نهایی نسبت به مدل پایه تغییری نشان نداده است؛ با این حال، این امر لزوماً به معنی عدم بهبود کیفیت مدل نیست، زیرا ممکن است بهبود اصلی در سطح امتیاز دهی رخ داده باشد و در آستانه ثابت به تغییر برجسته نهایی منجر نشده باشد. لذا برای دآوری دقیق تر، اتکا به ROC/PR که مبتنی بر امتیاز هستند، ضروری تلقی می گردد.




در ROC مربوط به LogReg+PCA (Tuned) مقدار $AUC \approx 0.876$ گزارش شده است که نسبت به مدل پایه افزایش جزئی نشان می دهد. این افزایش به صورت تحلیلی چنین تفسیر می شود که رتبه بندی بر اساس نمره پیش بینی شده اندکی بهبود یافته است؛ بنابراین، در صورت نیاز به تنظیم آستانه، انعطاف پذیری بیشتری در حفظ trade-off مطلوب میان TPR و FPR انتظار می رود. با توجه به تعریف ROC-AUC به عنوان مساحت زیر منحنی ROC مبتنی بر امتیاز، این نتیجه به عنوان نشانه ای از بهبود آستانه ناوابسته تلقی می گردد.




در PR مربوط به LogReg+PCA (Tuned) مقدار $AP \approx 0.9025$ مشاهده شده است که نسبت به مدل پایه اندکی بالاتر است. این افزایش به عنوان بهبود محدود اما قابل دفاع در توان مدل برای رتبه بندی صحیح تر نمونه های مثبت و حفظ Precision در سطح های مختلف Recall تفسیر می شود. از آنجا که PR-Curve برای مطالعه خروجی طبقه بند دودویی و تحلیل trade-off میان Precision و Recall به کار می رود، این بهبود کوچک می تواند در سناریو های حساس به Recall مانند غربالگری پزشکی در انتخاب آستانه نقش تعیین کننده داشته باشد.




برای RF (Tuned)، ماتریس اغتشاش نیز همان الگوی دودویی $TP=21$ ، $FN=4$ ، $FP=6$ ، $TN=15$ را نشان داده است. بدین ترتیب، تفاوت رفتاری RF نسبت به LogReg در آستانه پیش فرض آشکار نشده و برای مقایسه منصفانه، تمرکز باید بر معیارهای آستانه-ناوابسته و همچنین تحلیل تعمیم پذیری (Learning Curve) قرار گیرد؛ زیرا مدل‌های درختی ensemble دارای ظرفیت بالا بوده و مستعد واریانس بیشتر در داده‌های کوچک هستند، و این اثر در Confusion Matrix یک آستانه ثابت الزاماً نمایان نمی‌شود.




در ROC مربوط به RF (Tuned)، مقدار $AUC \approx 0.855$ گزارش شده است که نسبت به LogReg+PCA پایین‌تر است. از این رو، نتیجه گرفته می‌شود که در مقیاس آستانه-ناوابسته، توان رتبه‌بندی نمونه‌های مثبت بالاتر از منفی‌ها در RF ضعیف‌تر بوده است؛ هرچند در آستانه ثابت، تصمیم دودویی مشابه مشاهده گردیده است. این تفاوت معمولاً در داده‌های کوچک می‌تواند با نوسان‌های برآورد، حساسیت به تنظیمات، یا نیاز به regularization شدیدتر توضیح داده شود.




در PR مربوط به RF (Tuned)، مقدار $AP \approx 0.8815$ مشاهده شده که از LogReg+PCA کمتر است. بر این اساس، عملکرد RF در حفظ Precision در سطوح مختلف Recall نسبت به LogReg ضعیفتر ارزیابی می‌شود؛ به ویژه از آن جهت که PR-Curve برای مطالعه رفتار طبقه بند دودویی بر مبنای trade-off کلاس مثبت به کار می‌رود و افت AP به صورت مستقیم به افت کیفیت رتبه‌بندی مثبت‌ها نسبت داده می‌شود.




برای AdaBoost (Tuned)، ماتریس اغتشاش تغییر مهمی نشان داده و مقادیر $TP=23$ ، $FN=2$ ، $FP=7$ ، $TN=14$ است. از این خروجی استنباط می‌شود که خطای FN کاهش یافته و در مقابل، FP افزایش یافته است؛ بنابراین، حساسیت (Recall) در آستانه پیش فرض بهبود یافته اما هزینه آن افزایش هشدار کاذب بوده است. این الگو معمولاً در کاربردهای پزشکی می‌تواند ترجیح داده شود، مشروط بر آنکه هدف اصلی کاهش از دست رفتن مثبت‌های واقعی تعریف شده باشد و ظرفیت سیستم برای پذیرش FP بیشتر وجود داشته باشد.



با این حال، در ROC مربوط به AdaBoost (Tuned)، مقدار $AUC \approx 0.826$ گزارش شده که نسبت به سایر مدل ها کمتر است. از این رو، چنین تفسیر می شود که اگرچه در یک آستانه ثابت، Recall بالاتری حاصل شده، اما کیفیت رتبه بندی کلی در تمام آستانه ها به اندازه LogReg مطلوب نبوده است. با توجه به تعریف ROC-AUC، پایین تر بودن این مقدار به معنای ضعف نسبی در جداسازی مثبت منفی بر مبنای امتیاز پیش بینی شده تلقی می گردد.




در PR مربوط به AdaBoost (Tuned)، مقدار $AP \approx 0.855$ مشاهده شده که از LogReg و حتی RF کمتر است. بر این اساس نتیجه گرفته می شود که هرچند با آستانه پیش فرض، کاهش FN حاصل شده، اما در مقیاس آستانه ناوابسته و در trade-off کلی Precision-Recall، کیفیت رتبه بندی مثبت ها محدودتر بوده است. بنابراین، بهبود مشاهده شده در Confusion Matrix بیشتر به انتخاب آستانه نسبت داده می شود تا به برتری پایدار در کل دامنه آستانه ها.




۷-۳ Learning Curve و تحلیل بایاس-واریانس


در Learning Curve مربوط به LogReg+PCA (Tuned) ، مشاهده می شود که با افزایش اندازه داده آموزشی، امتیاز آموزش کاهش یافته و امتیاز اعتبارسنجی افزایش یافته است؛ به عبارت دیگر، شکاف تعمیم (generalization gap) با اضافه شدن داده کاهش نشان می دهد. این الگو به صورت کلاسیک به کاهش واریانس و بهبود تعمیم پذیری نسبت داده می شود و به طور نظری نیز کاهش واریانس با افزایش داده آموزشی در ادبیات scikit-learn مورد اشاره قرار گرفته است.



در Learning Curve مربوط به RF (Tuned) ، امتیاز آموزش در نمونه های کم بسیار بالا گزارش شده و همزمان امتیاز آزمون اعتبارسنجی در بخش قابل توجهی از دامنه پایین تر باقی مانده است؛ لذا وجود واریانس بالا و گرایش به overfitting در داده های کم محتمل تلقی می گردد. چنین الگویی معمولاً با نیاز به داده بیشتر یا محدود سازی ظرفیت مدل (تنظیمات کنترلی مانند عمق، حداقل نمونه برگ، و ...) تبیین می شود و با مفهوم کاهش واریانس با داده بیشتر هم راستا است.




در Learning Curve مربوط به AdaBoost (Tuned) نیز در حجم های کم داده، امتیاز آموزش بسیار بالا گزارش شده و سپس با افزایش داده، شکاف میان آموزش و آزمون کاهش نشان داده است. از این مشاهده نتیجه می شود که مدل در حجم های کم مستعد overfitting بوده اما با افزایش داده، بخشی از واریانس کنترل شده است؛ با این حال، با توجه به نتایج ROC/AP پایین تر، بهبود تعمیم پذیری در این مدل الزاما به برتری آستانه-ناوابسته منجر نشده و بیشتر به عنوان کاهش نسبی شکاف تعمیم تفسیر می گردد.




۷-۴ Calibration Curve و پایایی احتمال های پیش بینی شده


در Calibration Curve مربوط به LogReg+PCA (Tuned)، نزدیکی نسبی منحنی به خط قطری (perfect calibration) مشاهده می شود؛ بنابراین، احتمال های پیش بینی شده در بسیاری از بازه ها با فراوانی تجربی رخدادها هم خوانی مناسبی نشان می دهند. در چارچوب تعریف Calibration Curve به عنوان نموداری برای سنجش میزان کالیبره بودن احتمال های خروجی و نمایش قابلیت اتکای probability ها (Reliability Diagram)، این نتیجه به عنوان نشانه ای از کیفیت مناسب تخمین احتمال تفسیر می گردد.



در Calibration Curve مربوط به RF (Tuned)، انحراف های بیشتری نسبت به خط قطری مشاهده می شود؛ لذا احتمال های خروجی در برخی بازه ها بیش اعتماد (overconfident) یا کم اعتماد (underconfident) ارزیابی می گردند. با توجه به اینکه Calibration Curve دقیقاً برای سنجش تطابق احتمال پیش بینی شده با احتمال تجربی به کار می رود، چنین انحراف هایی معمولاً به عنوان انگیزه ای برای کالیبراسیون پس از آموزش مانند روش های مبتنی بر sigmoid یا isotonic مطرح می شود.



در Calibration Curve مربوط به AdaBoost (Tuned)، ناپایداری و انحراف های محسوس تری در برخی بازه ها مشاهده می شود؛ از این رو، اتکاپذیری probability های خروجی در همه بازه ها هم سطح با LogReg ارزیابی نمی گردد. مطابق تعریف Calibration Curve در scikit-learn، این وضعیت به معنای آن است که اعداد احتمال ارائه شده الزاماً تعبیر پذیر به عنوان احتمال واقعی رخداد نیستند، مگر آنکه کالیبراسیون تکمیلی اعمال شود.




توضیح پذیری مدل ها با SHAP برای مدل های بدون PCA


در این بخش، به منظور تبیین سهم ویژگی ها در پیش‌بینی مدل‌ها، از SHAP استفاده شد. مطابق تعریف، `shap.Explainer` به عنوان رابط اصلی برای توضیح پذیری مدل‌ها و توابع پیش‌بینی به کار گرفته می‌شود و در مدل های درختی نیز می‌تواند از توضیح دهنده های مناسب مانند `TreeExplainer` بهره ببرد؛ همچنین برای خروجی های احتمالاتی، امکان تفسیر در فضای احتمال `predict_proba` در `TreeExplainer` مستند شده است.

SHAP برای [No PCA] LogReg (Untuned)

در نمودار Beeswarm، بیشترین اثرگذاری مربوط به ویژگی های `cat_cp_0`، `num_chol`، `cat_ca_0`، `cat_thal_2` و `cat_thal_3` مشاهده شد. از الگوی رنگ-جهت اثر استنباط شد که فعال بودن برخی دسته ها مثل `cp_0=1` عمدتاً اثر منفی بر خروجی کلاس مثبت داشته، در حالی که عدم فعال بودن آن `cp_0=0` در بسیاری نمونه ها اثر مثبت ایجاد کرده است. همچنین برای متغیرهای عددی مانند `chol`، پراکندگی SHAP نشان داد که تغییرات مقدار ویژگی می‌تواند خروجی را در هر دو جهت جا به جا کند، اما روند غالب در داده حاضر به صورت کاهشی در سطوح بالاتر مشاهده شده است. این نتیجه نشان داد که حتی در مدل خطی، تعامل بین One-Hot و ویژگی های عددی باعث شکل گیری الگوهای تفسیری معنادار شده است.




را داشته اند و پس از آن `cat_ca_0` و دسته های `thal` قرار گرفته اند. همچنین مشاهده شد که مجموع سایر ویژگی ها هنوز سهم قابل توجهی دارد؛ بنابراین نتیجه گرفته شد که تصمیم مدل صرفا با یک یا دو ویژگی تعیین نشده و مجموعه ای از ویژگی ها به صورت تجمعی نقش آفرینی کرده اند.




SHAP برای RF (Untuned) [No PCA]

در Beeswarm مربوط به RF، ویژگی های `cat_cp_0`، `cat_thal_2`، `num_oldpeak` و `num_thalach` در بالاترین رتبه قرار گرفتند. الگوی پراکندگی نشان داد که RF نسبت به ویژگی های غیر خطی مانند `oldpeak` حساسیت بالاتری دارد و اثر ویژگی ها به صورت غیر متقارن و آستانه ای نیز بروز کرده. SHAP در مورد `thalach` نیز مشاهده شد که مقادیر بالاتر غالبا با افزایش خروجی کلاس مثبت همراه شده است.




در نمودار Bar، اهمیت `cp_0` و `thal_2` همچنان برتر باقی ماند و سپس `oldpeak` و `thalach` قرار گرفتند. بنابراین نتیجه گرفته شد که RF الگوی تصمیم خود را عمدتاً بر پایه چند ویژگی کلیدی بنا کرده است، هر چند سهم سایر ویژگی ها نیز حذف پذیر تلقی نشد.




SHAP برای AdaBoost (Untuned) [No PCA]

در Beeswarm این مدل، `cat_cp_0` و `num_chol` و `num_thalach` در کنار `cat_thal_2` بیشترین اثر را نشان دادند. نسبت به RF، دامنه SHAP کوچک تر مشاهده شد که می تواند نشان دهنده تقسیم اثر بین تعداد زیادی قاعده ضعیف آموز (stumps) یا حساسیت کمتر به تغییرات پیوسته باشد. همچنین حضور `cat_sex_0` و `num_age` در رتبه های بالاتر بیانگر آن بود که AdaBoost از برخی متغیرهای جمعیت شناختی نیز برای تفکیک استفاده کرده است.





در نمودار Bar، اهمیت ویژگی‌ها نسبتاً پخش‌تر گزارش شد و مجموع سایر ویژگی‌ها سهم معناداری داشت. بنابراین نتیجه گرفته شد که AdaBoost (Untuned) برخلاف RF که چند ویژگی کلیدی را برجسته می‌کرد، اثر را در ویژگی‌های بیشتری توزیع کرده است.



SHAP برای RF (scaled preprocess) (Untuned) [No PCA]


در Beeswarm و Bar این مدل، الگوی اهمیت و جهت اثر تقریباً مشابه RF (Untuned) مشاهده شد. این هم‌گرایی به عنوان یک نتیجه مورد انتظار تفسیر شد، زیرا مدل‌های درختی نسبت به مقیاس بندی ویژگی‌های عددی حساسیت کمتری دارند و تقسیم‌های درختی بر اساس ترتیب/آستانه داخلی انجام می‌شود. لذا نتیجه گرفته شد که افزودن مقیاس بندی به ورودی RF تغییر بنیادین در منطق تصمیم ایجاد نکرده است.






SHAP برای RF (Tuned) [No PCA]

در Beeswarm مدل RF (Tuned)، همچنان `cat_cp_0` و `cat_thal_2` و `num_oldpeak` و `num_thalach` مهم ترین عوامل باقی ماندند. با این حال، نسبت به نسخه `Untuned`، جابه جایی جزئی در رتبه ها به ویژه ارتقای `thalach` مشاهده شد که می تواند ناشی از تنظیم های پیرامترها و تغییر نحوه تقسیم های درختی باشد. بنابراین نتیجه گرفته شد که `tuning` ساختار کلی ویژگی های مهم را تغییر نداده، اما شدت اثر برخی ویژگی ها را تعدیل کرده است.




در نمودار `Bar` نیز همین الگو تأیید شد و اختلاف اهمیت بین چند ویژگی اول نسبتاً محدود بود؛ لذا تصمیم مدل به صورت چند عاملی و بر پایه چند ویژگی نزدیک به هم شکل گرفته است، هرچند `cp_0` و `thal_2` در صدر باقی مانده اند.




AdaBoost (Tuned) [No PCA] برای SHAP

در Beeswarm مدل AdaBoost (Tuned)، شدت اثر `cat_cp_0` و `cat_thal_2` بسیار برجسته تر از نسخه Untuned مشاهده شد و `num_oldpeak` نیز نقش پررنگی داشت. این تغییر نشان داد که tuning باعث شده است تمرکز مدل بر ویژگی های کلیدی تر افزایش یابد و سهم ویژگی های کم اهمیت کاهش پیدا کند.



در نمودار Bar نیز همین نتیجه تقویت شد؛ به گونه ای که cp_0 و thal_2 با فاصله معنی دار در رتبه های اول قرار گرفتند و سپس oldpeak و ca_0 دیده شدند. بنابراین نتیجه گرفته شد که AdaBoost (Tuned) نسبت به نسخه Untuned تمرکز ویژگی بیشتری پیدا کرده است و این موضوع می تواند به پایداری تصمیم در برخی سناریوها کمک کند، هرچند باید همزمان با معیارهای عملکردی (ROC/PR/Calibration) تفسیر گردد.



جمع بندی نهایی:

در جمع بندی نتایج این پروژه، یک خط لوله استاندارد و قابل اعتماد برای پیش بینی بیماری قلبی طراحی و ارزیابی شد که در آن پیش پردازش داده ها شامل تفکیک ویژگی های عددی و گسسته، جایگذاری مقادیر و کد گذاری مناسب به صورت یکپارچه در قالب Pipeline پیاده سازی گردید تا از بروز نشت اطلاعات در مراحل اعتبار سنجی جلوگیری شود. تحلیل اکتشاف از جمله بررسی همبستگی و مصورسازی های کاهش بعد مانند PCA و t-SNE نشان داد داده ها دارای هم پوشانی معنادار بین کلاس ها هستند و بنابراین انتظار خطای اجتناب ناپذیر در برخی نواحی تصمیم منطقی است. همچنین آزمایش کنترل شده روی Random Forest در حالت با و بدون StandardScaler تأیید کرد که مدل های درختی نسبت به مقیاس ویژگی ها حساسیت اندکی دارند و اعمال نرمال سازی برای آن ها مزیت محسوسی ایجاد نمی کند، در نتیجه انتخاب تبدیل ها به صورت هدفمند و متناسب با نوع مدل انجام شد.

در بخش مدل سازی و بهینه سازی، سه خانواده متفاوت شامل Logistic Regression به عنوان مدل پایه و تفسیر پذیر، Random Forest برای یادگیری الگو های غیر خطی و تعاملات و AdaBoost به عنوان روش boosting ترتیبی با پروتکل یکسان و معیارهای چند گانه مقایسه شدند. نتایج تیونینگ و ارزیابی آستانه ناوابسته ROC-AUC و PR-AUC/AP نشان داد که نسخه های بهینه سازی شده به ویژه Logistic Regression همراه با PCA از نظر پایداری و تفکیک کلی عملکرد رقابتی تری ارائه می دهند، در حالی که تحلیل ماتریس در هم ریختگی روی داده آزمون بیانگر یک بده بستان مهم بود AdaBoost تیون شده در برخی سناریو ها منجر به کاهش منفی های کاذب (FN) شد اما در مقابل، مثبت های کاذب (FP) افزایش یافت. این یافته از منظر کاربرد پزشکی اهمیت دارد، زیرا انتخاب نهایی مدل باید با توجه به هدف سیستم غربالگری با اولویت کاهش FN یا تصمیم گیری دقیق با کنترل FP و سیاست هزینه محور تعیین شود، همچنین استفاده از منحنی های ROC/PR، یادگیری (Learning Curve) و کالیبراسیون (Calibration Curve) تصویر جامع تری از رفتار مدل ها در آستانه ها و اندازه های مختلف داده فراهم کرد.

در نهایت، بخش توضیح پذیری با SHAP به عنوان مکمل ارزیابی کمی به کار گرفته شد تا علاوه بر مقایسه عملکرد، منطق تصمیم گیری مدل ها نیز روشن شود. بررسی نمودارهای SHAP (beeswarm و bar) برای نسخه های بدون PCA امکان تفسیر مستقیم اهمیت ویژگی ها را فراهم کرد و نشان داد که مدل های مختلف ممکن است بر جنبه های متفاوتی از داده تکیه کنند، به ویژه مدل های درختی و boosting الگوهای غیر خطی و آستانه ای را پررنگ تر منعکس کردند. بنابراین، نتیجه گیری کلی پروژه این است که یک راهکار قابل اتکا برای این مسئله نیازمند ترکیب هم زمان طراحی درست خط لوله، ارزیابی چند معیاره و آستانه ناوابسته، و توضیح پذیری است؛ و برای توسعه های آتی، تنظیم آستانه تصمیم بر مبنای هزینه FN/FP و همچنین کالیبراسیون پس آموزش برای مدل های غیر خطی می تواند کیفیت تصمیم سازی را در شرایط واقعی بهبود دهد.